Иван Леонтьев

ИИ-разработчик (Claude Code, LLM-агенты)

- Ульяновск (МСК+1), удалённо
- Почта: leontjev.ivan.2005@gmail.com
- Telegram: @Neorlav
- Сайт с демо и кейсами: leontjev-ivan.github.io · GitHub: leontjev-ivan

О СЕБЕ

Разрабатываю продукты на LLM: ИИ-агентов для диалогов с клиентами, конвейеры обработки текста и изображений, Telegram-ботов и Mini App вокруг них. Архитектуру, контракты и критерии приёмки задаю сам, реализацию отдаю агентам Claude Code, результат принимаю по тестам, ревью диффа и независимой проверке вторым агентом. Качество ИИ меряю на боевых данных: прогоняю реальные диалоги, модели выбираю замером на контрольных кейсах, считаю стоимость каждого вызова. Год в команде заказной разработки: вывел в продакшен два ИИ-агента, всего работал в 33 клиентских проектах.

ОПЫТ РАБОТЫ

Команда заказной разработки (удалённо) · декабрь 2025 - ноябрь 2026

ИИ-разработчик

ИИ-агент бронирования для глэмпинг-курорта · основной разработчик, в продакшене

- Ведёт гостей в Telegram, WhatsApp, Instagram и MAX: подбирает виллы на даты, считает цену, сам оформляет бронь с предоплатой 50%, сложное передаёт оператору. К сентябрю 2026 в базе бота 956 гостей.
- Собрал датасет из 995 боевых диалогов и автодетектор провалов: в прежней версии провал был в 698 диалогах из 995, и все 41 дефект сидели в логике кода, а не в модели.
- Первая версия была агентом с вызовом функций (4 инструмента: свободные виллы, цена, заявка на бронь, передача оператору). После разбора провалов перенёс выбор действий в код: модель извлекает намерения и параметры, код решает, что делать, ответ режется на утверждения, и код сверяет цены, наличие и скидки с базой фактов. Ошибка уходит на переделку до 5 раз, потом диалог незаметно для гостя переходит к оператору.
- Приёмка новой версии: 410 ходов на боевых переписках без сбоев, 9 боевых броней сошлись с системой бронирования до рубля.
- Модель разбора намерений выбрал замером: все пять кандидатов прошли 8 из 8 контрольных кейсов, взял gemini-3.1-flash-lite, она в 20 раз дешевле Sonnet 5 и в 5 раз быстрее. Расход на модели снизился почти вдвое, до ~$6,5 в месяц на весь поток диалогов; медиана ответа 4 с.
- Написал автобронирование, дожим клиентов, поиск свободных дат. Стек: pydantic-ai, OpenRouter, aiogram 3, FastAPI, PostgreSQL, Redis.

ИИ-агент поддержки для сети магазинов франшизы · разработал первую версию и сопровождал в продакшене

- Отвечает сотрудникам в рабочих Telegram-группах по базе знаний из 354 записей. Три роли: привратник решает, отвечать ли, ответчик пишет ответ с учётом истории, проверяющий сверяет его с базой. Остальное бот передаёт оператору.
- База знаний лежит в промпте под кэшем, около 20 тыс. токенов. Новые записи дописываются в конец: правка середины сбрасывает кэш, и следующий вопрос дорожает в 4,6 раза.
- Подобрал схему проверки на 37 живых кейсах из боевого лога: 5,52 → ~1,3 ₽ за проверку, в 4,3 раза дешевле; 34 из 37 решений совпали с проверкой по полной базе.
- Базу пополняет оператор: на промахе бот показывает ему похожую запись, и формулировка вопроса добавляется к ней синонимом одной кнопкой.
- Стек: OpenAI SDK (OpenRouter), aiogram 3, aiosqlite.

Перевод писем с китайскими поставщиками · основной разработчик, в продакшене

- Конвейер на LLM из 4 шагов: анализ письма, подбор терминов из глоссария на 178 позиций (RAG), перевод, ревью. Текст на картинках из письма читает vision-модель.

- 126 переводов в месяц, 14,6 с на письмо, около $0,001 за перевод.
- Модель для ревью выбрал бенчмарком 4 моделей на тестовых письмах: все прошли 5 из 5, взял Gemini 3 Flash, она в 2,6 раза быстрее и в 4 раза дешевле Claude Haiku 4.5.
- Панель на Vue 3, REST API, приём из двух почтовых ящиков. Стек: LiteLLM, Langfuse, ChromaDB, FastAPI.

Mini App учёта питания для врача-эндокринолога · основной разработчик, работает у заказчика

- Переводит продукты в порции по методике врача, ведёт дневник пациента и кабинет врача. MVP собрал за один день, справочник на 154 позиции.
- Снимок этикетки или карточки товара vision-модель переводит в JSON (калории, БЖУ, вес упаковки): 1,8 с в замере, около $0,0005 за снимок. На снимке без таблицы БЖУ модель уверенно (0,95) выдумала цифры, поэтому их всегда подтверждает пользователь.
- Стек: FastAPI, aiogram 3, Vue 3, Gemini через OpenRouter.

Конструктор ИИ-администраторов для малого бизнеса · рабочий кабинет и демо-стенд для показа клиентам

- Владелец вносит услуги и цены и получает бота, который отвечает его клиентам в Telegram, WhatsApp, Instagram, ВК, MAX и на Авито. Чего бот не знает, он передаёт владельцу.
- Модель разбирает сообщение и формулирует ответ, а цены, расчёты и решения остаются за кодом: числа в ответ подставляет код, поэтому модель не может их выдумать.
- 1060 автотестов, набор из 29 ситуаций на настоящей модели, медиана хода 4,3 с. Стек: FastAPI, PostgreSQL.

ЕЩЁ ПРОЕКТЫ ЗА ГОД

- Свои инструменты для работы с агентами: параллельные сессии Claude Code, ревью свежим агентом, MCP-серверы (Telegram, управление компьютером), мультиагентный прототип на Claude Agent SDK
- Шлюз к ИИ-провайдерам для команды: один ключ и OpenAI-совместимый адрес для всех провайдеров, ротация ключей, переключение при сбое, учёт расходов и лимиты
- Осмотр контейнеров по фото: vision-модель ищет повреждения, код ставит коды и смету (прототип, единственный разработчик)
- Решатель учебных задач: решает одна модель, проверяет другая, учёт стоимости каждого шага (прототип, единственный разработчик)
- Бот-визажист: vision-модель сравнивает фото клиентки с референсом и даёт пошаговый план макияжа (прототип)
- Сервис подготовки к защите работы: 20 вопросов комиссии по загруженному документу (прототип)
- Репосты между Telegram-каналами: модель проверяет и переписывает посты, убирает дубли, рисует карточки
- Сервис проверки, как сайт видят ИИ-поисковики (граф на LangGraph), и конвейер SEO-статей с одобрением человеком (закрытая бета)
- Трекер задач команды в Telegram: голос и текст превращаются в действия через LLM
- Также: агрегатор данных фондового рынка с подпиской и оплатой ЮKassa (основной разработчик), Telegram-боты для бизнеса с AmoCRM и Google Таблицами, сопровождение серверов и сайтов

ДЕМО С КОДОМ

- rag-bot, бот по документам: гибридный поиск в Qdrant, LangGraph, ответы со ссылками; эталонный факт в 95% ответов на 22 вопросах, отказ на всех 5 вопросах вне базы
- Прочие демо: Mini App каталога, бот записи, парсер в Excel

НАВЫКИ

- **ИИ и LLM:** Claude Code, Claude Agent SDK, LLM API (OpenAI, Anthropic, Gemini, OpenRouter), агенты на pydantic-ai, tool calling, structured output, RAG (Qdrant, ChromaDB), LangGraph, LiteLLM, Langfuse, кэш промпта, vision-модели, MCP, оценка качества на реальных данных
- **Бэкенд:** Python, FastAPI, aiogram 3, SQLAlchemy, Pydantic, PostgreSQL, Redis, Docker, Linux, Nginx
- **Фронт:** Vue 3, Telegram Mini App
- **Тесты:** pytest, Playwright